

# Rapport Mini-projet

**Projet :** Xporters

**Nom du groupe :** Autobus

**Membres du groupe:**

Marion Pobelle <[marion.pobelle@u-psud.fr](mailto:marion.pobelle@u-psud.fr)>

Garance Roux <[garance.roux@u-psud.fr](mailto:garance.roux@u-psud.fr)>

Romain Soliman <[romain.soliman@universite-paris-saclay.fr](mailto:romain.soliman@universite-paris-saclay.fr)>

Elie Raspaud(ne fait plus l'UE) <[elie.raspaud@u-psud.fr](mailto:elie.raspaud@u-psud.fr)>

Aimane Benamma" <[aimane.benammar@universite-paris-saclay.fr](mailto:aimane.benammar@universite-paris-saclay.fr)>

Lucas Foissey <[lucas.foissey@u-psud.fr](mailto:lucas.foissey@u-psud.fr)>

**Challenge url :** <https://codalab.lri.fr/competitions/652>

**Github repo of the project :** <https://github.com/Ladiscou/AUTOBUS2>

## **Motivation du choix XPORTERS**

Nous avons décidé de travailler sur le projet Xporters. En effet, il s'agissait du seul problème de régression nous ayant été présenté et son contexte actuel a attiré notre curiosité. Le nombre de caractéristiques à gérer ainsi que leurs natures définissent une application unique et proche de la réalité de notre environnement.

Nous étions aussi intéressé d'apprendre par le biais de cet exercice l'utilisation du machine learning dans des cas concrets.

## **Données et description du problème:**

Le problème consiste à prédire le nombre de véhicules qui traversant l'autoroute selon divers paramètres décrits par les 59 features/dimensions des datas. Les datas représentent chacune des conditions influençant le nombre d'usager sur la route comme le nombre de millimètre de pluie par heure.

Les statistiques des données utilisées sont résumées dans le **Tableau 1** (cf *Annexe 1*).

## **Approche de chaque groupe**

### Preprocessing :

Le but de cette partie était dans un premier temps de sortir les outliers (données isolées pouvant perturber l'algorithme d'apprentissage) de notre set de données, puis de réduire la dimension des données pour faciliter le travail dessus par la suite. Nous avons dans un premier temps utilisé *LocalOutlierFactor* ([1], cf *Annexe 2*) qui nous a permis de mettre à jour nos données. Nous avons décidé, après plusieurs tests, d'enlever 8% des données ce qui nous semblait un juste équilibre pour éviter d'en enlever trop. Nous avons ensuite décidé de réduire le nombre de dimension de nos données en utilisant l'outil *PCA* ([2]) qui projette les dimension de façon à fusionner les données utiles entre elles. Pour finir nous avons utilisé *SelectKBest* ([3])

pour calculer le score de l'importance des features du modèle et ainsi obtenir un classement de l'importance des features.

### Modélisation :

Nous avons commencé par choisir 5 modèles provenant du module *scikit-learn*, ceux-ci devant être muni d'une instance applicable à un problème de régression. Afin de trouver le modèle le plus adapté à nos données, il nous a fallu calculer le score de chacun des modèles choisis sur un ensemble de validation, obtenus à partir de la fonction *train\_test\_split* ([4]) appliquée aux données. Les hyper-paramètres utilisés pour cette étape ont été choisis de manière arbitraire car notre premier objectif était de sélectionner un modèle approprié.

Après avoir sélectionné le modèle le plus adapté à nos données, nous en avons étudié les caractéristiques : fonctionnement, hyper-paramètres et applications furent l'objet de notre intérêt. Nous devions ainsi définir quels étaient les hyper-paramètres de notre modèle les plus pertinents à utiliser sur nos données. Afin de mener notre recherche, nous avons décidé d'utiliser la méthode *Random Search* ([5]), car de nombreuses combinaisons d'hyper-paramètres étaient à essayer.

Nous avons commencé par chercher quels étaient les hyper-paramètres les plus intéressants à utiliser sur notre modèle. Après en avoir établi une courte liste, nous nous sommes documenté sur chacun d'entre eux afin de définir des intervalles de recherche pertinents et ainsi rendre notre algorithme de recherche plus efficace. Les paramètres clés de notre recherche étaient de prévenir les situation dites d'*over-fitting* ([6]) et de réduire notre temps de recherche.

Ainsi, nous avons pu définir quel était le modèle le plus efficace à appliquer à notre problème, ainsi que les hyper-paramètres les plus intéressants à utiliser pour une étude pertinente de nos données.

### Visualisation :

Notre partie du travail était de représenter au mieux les résultats. La première approche a été de savoir quels graphiques seraient les plus pertinents, ce qui variait en fonction du projet choisi. Pour cela, nous avons fait une liste simplifiée des algorithmes souvent utilisés lors de projets d'intelligence artificielle. En comparant notre liste avec les consignes demandées, nous avons conclu qu'il fallait faire une classification des données et une visualisation de régression. Le problème était qu'on ne savait pas sur quelles données travailler, ce que nous développerons plus dans la partie des premières approches.

## **Organisation de notre groupe**

Le premier binôme constitué de Lucas et Elie, travaille sur la partie preprocessing de notre projet. L'objectif était de faire un premier traitement sur les données avant de travailler dessus en enlevant les données inintéressante et en réduisant leur dimension.


Le second binôme constitué de Marion et de Aimane, travaille sur la partie modélisation de notre projet. Leur objectif est de trouver le modèle le plus adapté aux données du problème ainsi que les hyper-paramètres correspondant les plus intéressants.

Le dernier binôme constitué de Garance et Romain, travaille sur la partie visualisation de notre projet. Leur objectif est de représenter au mieux les résultats obtenus afin de pouvoir visualiser quelle solution de notre projet est la plus pertinente.

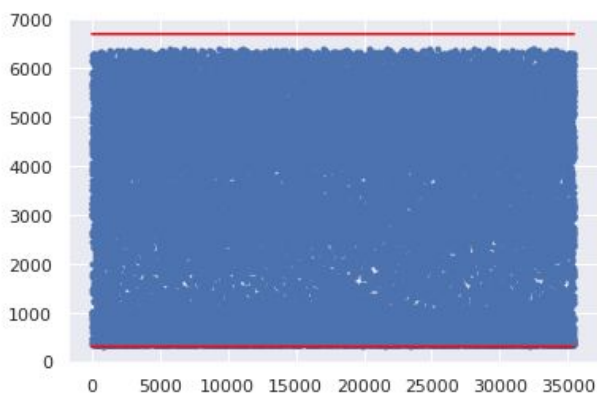
## Premiers résultats

### Preprocessing :

Après avoir observé la répartition des données grâce aux outils de visualisation de pyplot et avoir fait différents tests pour comprendre l'algorithme des k-voisins nous avons décidé de trouver les outliers en utilisant cet algorithme avec en paramètre la moitié du nombre de donnée (on notera que cette fonction étant très gourmande en terme de calculs nous avons créer une fonction plus légère qui divise le jeu de donnée en 4) ce qui a permis d'enlever surtout les données extrêmes comme le montre les graphes ci dessous:



Donnée avant le filtrage (target en y, index en x)



Donnée après le filtrage

Par la suite nous avons décidé de réduire le nombre de dimension de nos données à 48. En effet cela nous permettait de conserver les données les plus intéressantes que nous observions avec linearRegression([7]) qui nous permet de faire certaines opérations sur notre jeu de données notamment une évaluation du score.

Pour finir nous avons fait le classement des features et obtenu un top 10 qui classait les features selon un score d'importance:

	Specs	Score
2	rain_1h	2795.129136
16	weather_main_Rain	122.124013
1	temp	7.614380
11	weather_main_Clouds	7.377375
9	year	7.106427
10	weather_main_Clear	6.165868
48	weather_description_sky_is_clear	5.133682
8	month	2.312206
15	weather_main_Mist	2.250224
38	weather_description_mist	2.250224

On notera que le score obtenu pour rain\_1h paraît très élevé par rapport à d'autres scores que nous attendions précédemment notamment le jour de la semaine et l'horaire.

### Modélisation :


Les premiers résultats sur les données obtenus par notre binôme à l'aide du fichier README.ipynb ([8]) sont résumés dans le **Tableau 2** (cf Annexe 3). Ces résultats montrent que le modèle le plus adapté à notre problème est le modèle *Decision Tree*, avec les hyper-paramètres *min\_samples\_split*, *min\_samples\_leaf*, *max\_features* et *max\_depth*. Le score obtenu pour ce modèle pour la cross-validation est inférieur à 0.95 mais reste cependant excellent en prenant en compte la taille de l'ensemble des données d'entraînement et les risques d'over-fitting. Lors de la recherche du meilleur modèle pour nos données, nous avons été confronté à certains résultats aussi mauvais que étonnants. En effet, certains modèles obtenaient des résultats aberrants tels que des scores négatifs. Il n'était pas question d'utiliser ces modèles !

Le modèle *Decision Tree* structure les données suivant deux phases : une première phase de construction qui, sur la base d'un ensemble de données, applique un processus récursif de division de l'espace des données. On cherche lors de ce processus, à maximiser la variance inter-classes. Il faut donc faire attention à ne pas fixer une profondeur trop élevée, au risque que l'algorithme soit trop centralisé sur un set de données et donc non-généralisable. La deuxième phase de l'algorithme consiste en la suppression des branches peu représentatives des données dans l'arbre, afin d'avoir un arbre le plus généralisable à d'autres données possibles.

### Visualisation :


Il s'agissait en partie de représenter les résultats des autres binômes, ce qui était compliqué puisqu'on ne pouvait pas travailler sur le même code en même temps. On a donc décidé de traiter les données dont on disposait sur le fichier de référence ([README.ipynb](#) ([8])). Il fallait faire en sorte que l'algorithme fonctionne avec n'importe quel tableau.

Nous avons fait deux graphiques, le **Graphique 1** ci-dessous représente les données classées par l'algorithme K-means([9]). Le tableau donné *data* était de dimension (38563, 60). Afin de traiter ces données, il faut d'abord convertir le tableau *data* en deux dimensions. Nous nous sommes donc inspirés de la fonction PCA ([2]) dont le groupe Preprocessing s'est servi. Comme les valeurs varient entre  $10^{-3}$  et  $10^5$ , il faut avant tout normaliser le tableau *data* avant d'appliquer la fonction Principal Component Analysis (PCA) pour éviter des pertes de données à cause de la trop grande différence d'échelle. Nous avons donc obtenu le graphique suivant :




**Graphique 1** : classement des données par la fonction KMEANS

Le second graphique était plus simple à réaliser puisqu'on avait un graphique de référence (**Graphique 2**, voir ci-dessous) déjà implémenté dans le code README.ipynb ([8])



**Graphique 2** : graphique de référence

Il ne restait plus qu'à représenter un modèle de régression ajustée en utilisant la fonction `DecisionTreeRegressor` ([10]). On a ainsi obtenu une courbe une sorte de courbe de tendance (voir le **Graphique 3** ci-dessous).



**Graphique 3** : courbe obtenue par `DecisionTreeRegressor`

## Annexes

### Annexe 1:

**Tableau 1 : Statistiques des données**

<b>Dataset</b>	<b>Num. Examples</b>	<b>Num. Variables/ features</b>	<b>Sparsity</b>	<b>Has categorical variables ?</b>	<b>Has missing data ?</b>
<b>Training</b>	<b>38563</b>	<b>59</b>	<b>0</b>	<b>0</b>	<b>0</b>
<b>Valid(ation)</b>	<b>4820</b>	<b>59</b>	<b>0</b>	<b>0</b>	<b>0</b>
<b>Test</b>	<b>4820</b>	<b>59</b>	<b>0</b>	<b>0</b>	<b>0</b>

### Annexe 2:

#### **Description de l'algorithme de filtrage pour détecter les outliers:**

(preprocessing part)

Dans notre cas d'utilisation l'algorithme a besoin des parametre suivants

-Le nombre de voisin pris en compte **k**

-le jeux de donnée **data**

-la taux de contamination correspondant au pourcentage de donnée que l'on veut considérer comme outliers **h**.

L'algorithme va calculer la "densité" de chaque point, c'est a dire calculer sa norme 2 par rapport au nombre de voisin **n** passer en paramètre puis il compare la densité des points par rapport à ses voisin, ceux ayant la plus faible densité sont alors considérés comme outliers, le tableau renvoi un tableau de dimension 1 et de même taille que le jeux de donnée ou chaque données ont été remplacées par un -1 si elles sont considérées comme outliers un 0 sinon.

La fonction filter suis donc le processus suivant:

Crée mon outil de LocaloutlierFactor de parametre **k** et **n**

Crée mon tableau **inliers** de -1 et 1 en appliquant l'outil a **data**

For **i**  $\in$  **inliers**:

Remplit un tableau **outliers** des indice des **i** == -1

Return outliers

Fonction de mise à jour des données:

Prend en paramètre mon tableau de donnée **data** et mon tableau **outliers**

For **i**  $\in$  **outliers**:

Enlève la donnée d'indice **i** dans **data**

Return **data**

Annexe 3 :

**Tableau 2 : Premiers résultats**

<b>Method</b>	<b>Nearest Neighbors</b>	<b>Linear SVM</b>	<b>RBF SVM</b>	<b>Decision Tree</b>	<b>Random Forest</b>
<b>Training</b>	<b>0.8733</b>	<b>0.1241</b>	<b>-0.0029</b>	<b>0.9489</b>	<b>0.3950</b>
<b>CV</b>	<b>0.73</b>	<b>0.12</b>	<b>-0.00</b>	<b>0.93</b>	<b>0.32</b>
<b>Valid(ation)</b>	<b>0.7424</b>	<b>-0.3535</b>	<b>-0.0035</b>	<b>0.9358</b>	<b>0.3844</b>



## References

- [1] Unsupervised outlier detection using Local Outlier Factor, bibliothèque sklearn.neighbors scikit-learn developers, 2007 - 2019, <https://scikit-learn.org/stable/modules/generated/sklearn.neighbors.LocalOutlierFactor.html#sklearn.neighbors.LocalOutlierFactor>
- [2] Principal component analysis, bibliothèque sklearn.decomposition scikit-learn developers, 2007 - 2019, <https://scikit-learn.org/stable/modules/generated/sklearn.decomposition.PCA.html?highlight=pca#sklearn.decomposition.PCA>
- [3] Select features according to the k highest, bibliothèque sklearn.feature\_selection scikit-learn developers, 2007 - 2019, [https://scikit-learn.org/stable/modules/generated/sklearn.feature\\_selection.SelectKBest.html?highlight=selectkbest#sklearn.feature\\_selection.SelectKBest](https://scikit-learn.org/stable/modules/generated/sklearn.feature_selection.SelectKBest.html?highlight=selectkbest#sklearn.feature_selection.SelectKBest)
- [4] Split arrays or matrices into random train and test subsets, bibliothèque sklearn.model\_selection scikit-learn developers, 2007 - 2019 [https://scikit-learn.org/stable/modules/generated/sklearn.model\\_selection.train\\_test\\_split.html?highlight=train\\_test\\_split#sklearn.model\\_selection.train\\_test\\_split](https://scikit-learn.org/stable/modules/generated/sklearn.model_selection.train_test_split.html?highlight=train_test_split#sklearn.model_selection.train_test_split)
- [5] Randomized search on hyper parameters, bibliothèque sklearn.model\_selection scikit-learn developers, 2007 - 2019, [https://scikit-learn.org/stable/modules/generated/sklearn.model\\_selection.RandomizedSearchCV.html?highlight=random%20search#sklearn.model\\_selection.RandomizedSearchCV](https://scikit-learn.org/stable/modules/generated/sklearn.model_selection.RandomizedSearchCV.html?highlight=random%20search#sklearn.model_selection.RandomizedSearchCV)
- [6] Définition d'overfitting, WILL KENTON Updated Jul 2, 2019, <https://www.investopedia.com/terms/o/overfitting.asp>
- [7] Ordinary least squares Linear Regression, bibliothèque sklearn.linear\_model, scikit-learn developers, 2007 - 2019 [https://scikit-learn.org/stable/modules/generated/sklearn.linear\\_model.LinearRegression.html?highlight=linearregression#sklearn.linear\\_model.LinearRegression](https://scikit-learn.org/stable/modules/generated/sklearn.linear_model.LinearRegression.html?highlight=linearregression#sklearn.linear_model.LinearRegression)
- [8] fichier README.ipynb, code de référence du projet <https://github.com/Ladiscou/AUTOBUS2>
- [9] K-Means clustering, bibliothèque sklearn.cluster.KMeans scikit-learn developers, 2007-2019, <https://scikit-learn.org/stable/modules/generated/sklearn.cluster.KMeans.html?highlight=k%20means#sklearn.cluster.KMeans>

[10] A decision tree regressor, bibliothèque `sklearn.tree`, scikit-learn developers, 2007-2019, <https://scikit-learn.org/stable/modules/generated/sklearn.tree.DecisionTreeRegressor.html?highlight=decisiontreeregressor#sklearn.tree.DecisionTreeRegressor>